2026년도 공공기관 용역과제

AI개발 수행내역서

과제명	ML 기반 인지 능력 점수 예측 모델 구축
담당자	김정호

2026년 4 월 03 일

AI개발 수행내용

1. 사업과제 : ML 기반 인지 능력 점수 예측 모델 구축

2. 개요 및 현황

2.1 추진배경 및 목적

○ 현대인의 수면 부족과 불규칙한 생활 습관이 심화됨에 따라, 이는 단순한 피로를 넘어 업무 효율성과 전반적인 삶의 질을 저하시키는 주요 원인으로 지목되고 있음.

○ 일상적 건강 지표(신체 활동량, 심박수, 스트레스 수준 등)가 개인의 '인지 수행 능력'에 미치는 영향을 데이터 기반으로 정량화하고 분석할 필요성이 대두됨.

○ 이에 따라 개인의 수면 및 생활 습관 데이터를 학습하여 인지 수행 능력 점수를 예측하는 머신러닝(ML) 기반 AI 모델을 개발하고자 함.

○ 예측 모델 구축 및 데이터 시각화를 통해 인지 능력에 가장 큰 영향을 미치는 주요 요인을 도출하고, 개인 맞춤형 수면 건강 관리 및 효율성 향상을 위한 객관적인 인사이트를 제공하는 것을 목적으로 함.

2.2 과제 범위

과제구분		내용
ML	데이터 전처리	데이터셋 수집 및 1차 상관관계 분석
		데이터 전처리 (연관성 낮은 변수 제거)
		데이터 표준화 (Ranking 또는 OneHot Encoding)
		Feature와 출력 변수의 상관관계 확인
	ML기반 인지 능력 점수 예측 모델 구축	예측 모델 평가 (RMSE, MAE 등) 및 선정
		예측모델 학습
		하이퍼파라미터 튜닝
		최적화 모델 추출
		최적화된 모델 평가 (MAE, MSE, R2, 및 예측)
	배포	프로토타입 구축 (Streamlit localhost)
		예측모델 웹기반 시스템 구축 (Streamlist cloud)
		클라우드 시스템 배포

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

■ **수집 및 관리 용이성**: 일반 대중이 별도의 장비 없이도 즉각 확인할 수 있는 공개 데이터를 활용함으로써, 웹 배포 시 사용자 접근성을 극대화하고 실시간 인지 능력 예측이 가능한 환경 구축.

○ 예측모델 개발 효율성

■ **모델 확장성**: 향후 웨어러블 및 모바일 기기와의 연동을 통해 정형화된 수치형 생체·생활 데이터를 확보할 경우, 모델의 정밀도와 재현율을 대폭 향상 가능. 특히 생활 습관 데이터를 기반으로 한 고도화된 시계열 예측 모델로의 확장성 보유.

○ 사회적 기여도 및 경제성

■ **국민 건강 및 생산성 기여**: 개인별 인지 상태에 대한 객관적 정량 지표를 제공함으로써 수면 부족으로 인한 사회적 생산성 손실을 방지하고, 전 국민의 삶의 질 향상에 기여.

■ **비용 절감 및 가치 창출**: 인지 저하 위험군을 조기에 식별하여 장기적인 사회적 의료 비용을 절감하며, 맞춤형 가이드라인 제공을 통해 디지털 헬스케어 분야의 실무적 효용성 증대.

2) AI 예측 분석모델 적용 대상

분석 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
개인 건강 및 인지 관리	- 일상 생활 및 수면 데이터 - 일별 수면 패턴 및 활동 데이터 - 수면의 질, 스트레스 등 핵심 지표가 포함된 데이터셋	수면 지표: 수면 시간 및 질, 수면 장애 여부 등 생체 지표: 스트레스 지수, 심박수(BPM) 등 활동 지표: 신체 활동량등 환경 변수: 요일(주중/주말), 기상 패턴 등	인지 능력 점수 예측

3) ML 분석모델 구축 프로세스

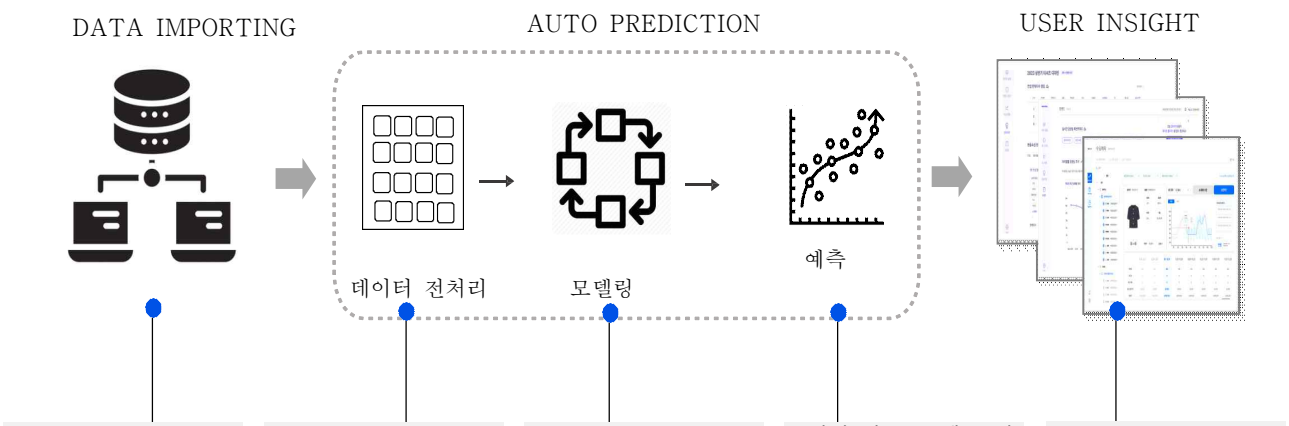

CDC National Health Interview Survey(2024 & 2025) 등 주요 보건 연구 지표를 기반으로 구성된 Kaggle 데이터셋

타겟 변수인 '인지 능력 점수'와의 상관계수 절대값이 0.05 미만인 변수들을 식별하여 분석 대상에서 제외함.

GridSearchCV를 통해 XGBoost의 핵심 파라미터를 자동 탐색하여 모델의 예측 오차 최소화 및 일반화 성능 확보

수면의 질, 스트레스 지수 등 8가지 핵심 생체 지표를 최종 모델에 입력하여 개인별 인지 성능 점수를 정량적으로

수면의 질, 스트레스 수준, 심박수 변동성을 결합 분석하여 인지 능력이 급격히 저하되는 '위험 구간'을 사전에 식별

연구개발 주요 결과물

3. 데이터 수집

- CDC 국립건강설문조사(2024), Sleep Foundation 인구통계 연구, Frontiers 수면학 학술지(2025) 및 프레이밍햄 심장 연구(Framingham Heart Study) 자료를 통합하여 구축된 Kaggle 공개 데이터셋을 활용함.

4. 데이터 분석

4.1 양적 변수 간 상관관계 분석 히트맵 (Correlational Heatmap of Quantitative Variables)

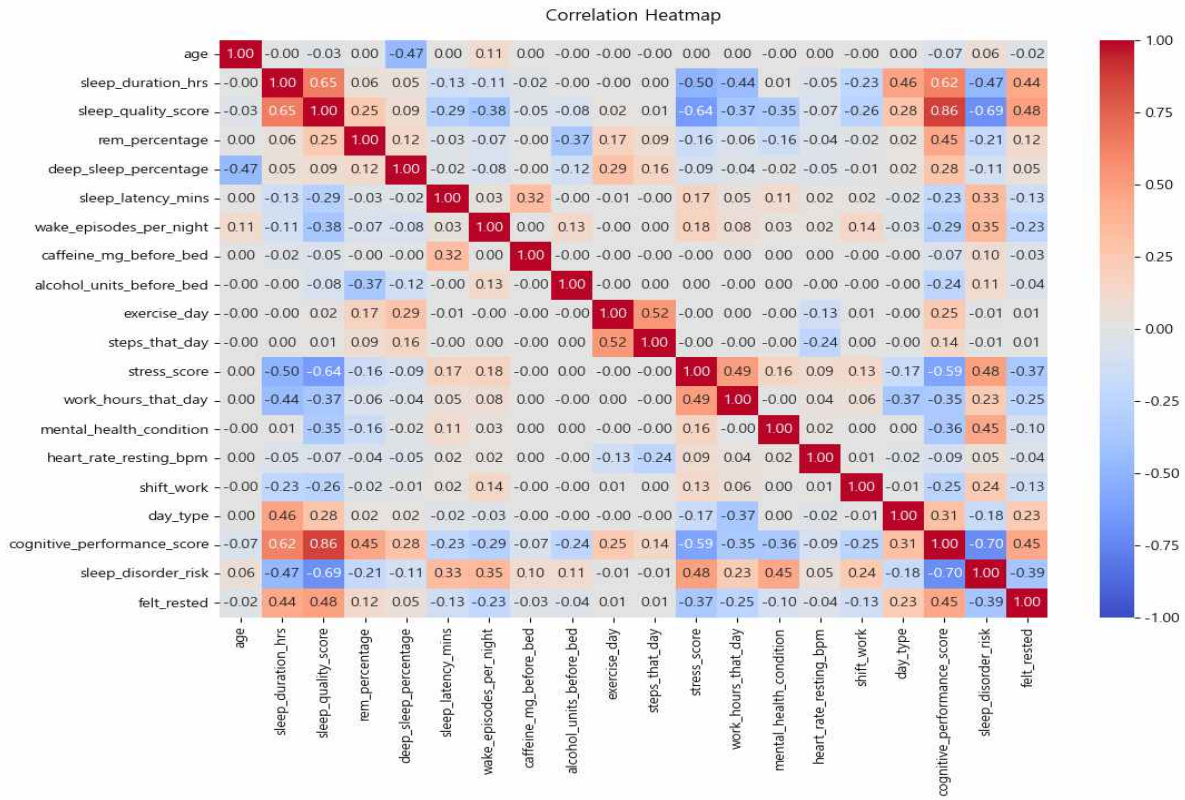

4.2 탐색적 데이터 분석

○ **핵심 변수 필터링**: 전체 데이터셋에 대한 1차 상관관계 분석 후, 타겟 변수와 상관계수 절대값이 0.3 이상인 유의미한 변수들만을 선별하여 2차 히트맵을 생성함.

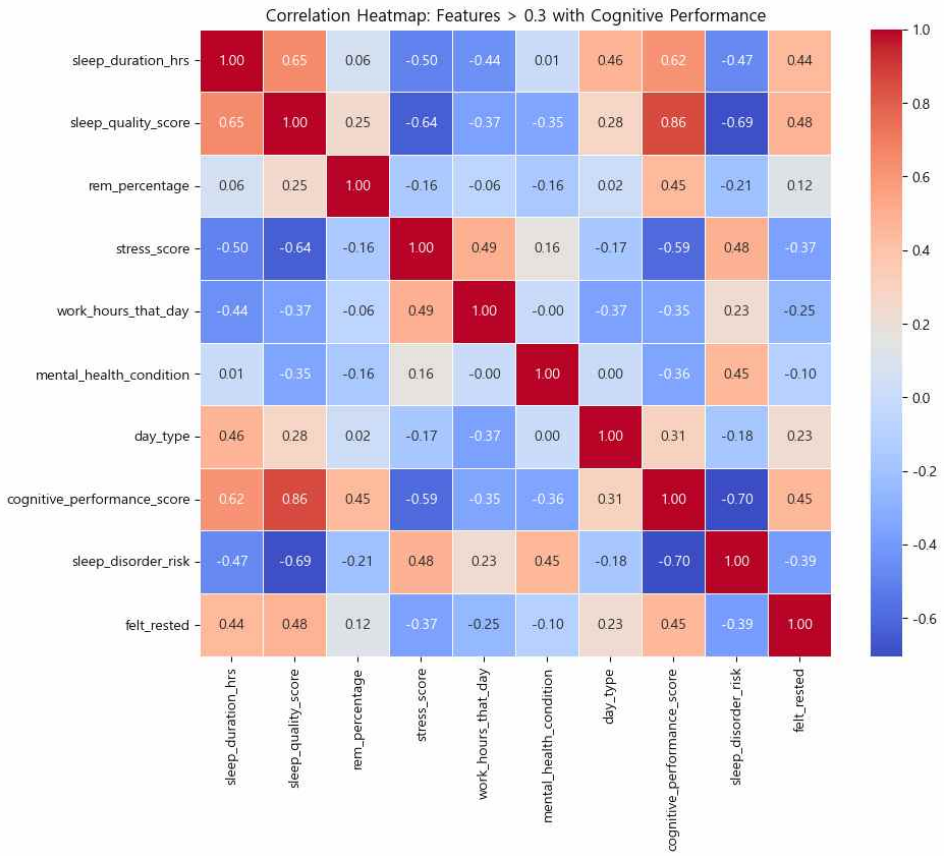

4.3 주요 변수 간 상관관계 분석 및 핵심 피처 식별

○ 데이터셋 내 수치형 변수 간 상관계수 분석을 실시한 결과, 타겟 변수인 '인지 수행 점수(Cognitive Performance Score)' 및 수면의 질'과 통계적으로 유의미한 상관성을 보이는 핵심 변수군을 식별함. 이를 통해 모델의 예측력을 극대화할 수 있는 최적의 입력 변수 조합을 도출함

○ **인지 수행 점수 (Cognitive Performance Score)**:인간의 고등 정신 기능인 기억력, 주의집중력, 의사결정 속도, 집행 기능(Executive Function) 등을 종합하여 수치화한 정량적 지표

Column Name	Description
나이	10 ~ 100세
BMI 카테고리	1(정상 체중), 2(과체중), 3(비만)
일일 걸음 수	0 ~ 20,000보
심박수 (평상시)	40 ~ 120 bpm
혈압	80 ~ 180 mmHg / 50 ~ 120 mmHg
수면 시간	0.0 ~ 24.0 시간
스트레스 지수	0.0 ~ 10.0
충분히 휴식한 느낌	0: 아니요, 1: 네
정신 건강 상태	0 (건강) ~ 3 (복합적 증상)
수면 장애 여부	0(없음), 1 (있음)

○ 피처 선별 및 상관성 검증

■ **수치형 변수 분석 (Scatter Plot)**: 선별된 수치형 변수(Quantitative Variables)와 인지 점수 간의 산점도를 작성하여, 데이터의 선형적 추세, 밀집도 및 이상치를 분석함으로써 변수 간의 직접적인 인과성을 검증함.

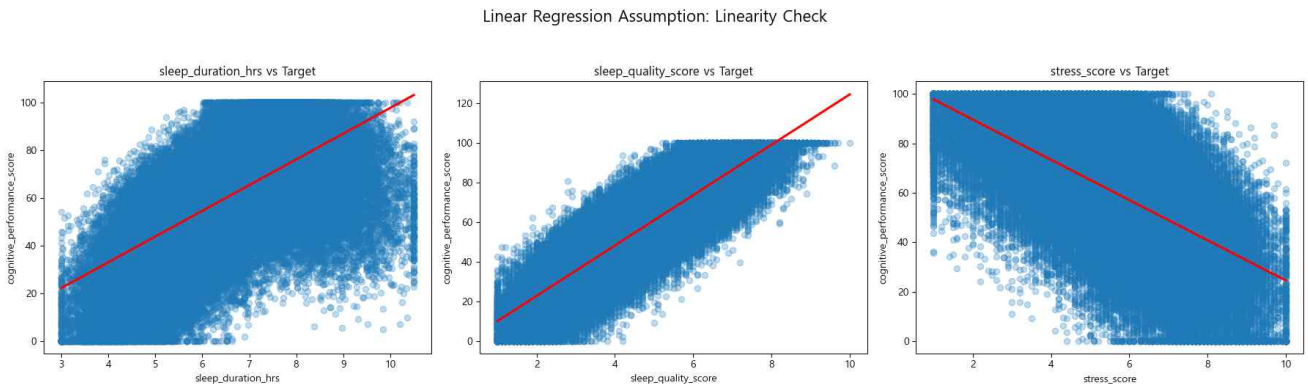

■ **범주형 변수 분석 (Box Plot)**: 성별, 수면 단계 등 질적/범주형 변수(Qualitative Variables)에 대해서는 박스 플롯을 활용하여 각 그룹별 인지 점수의 분포와 중앙값의 차이를 시각화함으로써, 해당 변수가 타겟 변수 예측에 미치는 유효성을 확인함.

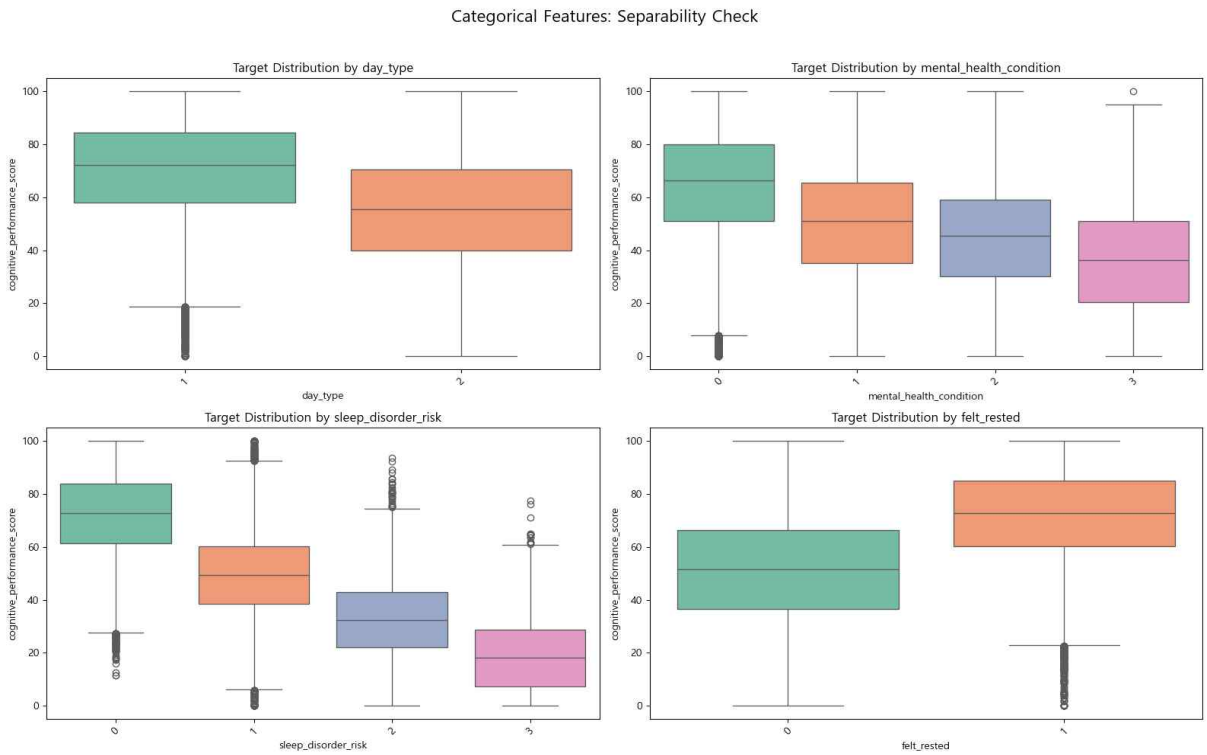

5. 모델정의 및 데이터 학습

5.1 모델정의 및 컴파일

○ **데이터 에코딩 및 표준화:** 질적 데이터의 서열성 유무에 따라 순서형 매핑과 원-핫 인코딩을 혼용하여 수치화 과정에서의 정보 왜곡을 방지함. 수면 시간, 심박수 등 단위가 상이한 양적 변수는 StandardScaler를 적용하여 평균 0, 분산 1의 표준 정규 분포로 변환하였음. 이를 통해 모델 파이프라인 내 피처 간 독립성을 확보하고 학습 수렴 속도를 최적화함.

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test = pd.DataFrame(X_test_scaled, columns=X_test.columns)
```

○ **예측 모델 알고리즘 선정**: 5종의 회귀 알고리즘을 대상으로 MSE, R^2 MAE 성능 지표를 산출하여 비교 분석하였음. 분석 결과, 결정계수(R^2)가 가장 높고 오차율이 낮은 XGBRegressor를 최적의 예측 모델로 최종 선정함. 이를 통해 인지 수행 점수 예측의 정밀도와 모델 안정성을 확보하였음.

	MSE	R2 Score	MAE
XGBoost	101.953211	0.792534	8.095163
Random Forest	108.694776	0.778815	8.342883
Linear Regression	111.335621	0.773441	8.442388
K-Nearest Neighbors	119.778865	0.756260	8.748416
Decision Tree	210.458899	0.571733	11.520177

○ **데이터 최적화(XGRegressor):** XGBRegressor의 예측 성능을 극대화하기 위해 GridSearchCV를 활용한 하이퍼파라미터 최적화를 수행함. 트리의 깊이(max_depth), 추정기 개수(n_estimators), 학습률(learning_rate) 등 핵심 파라미터 조합을 자동 탐색하여 모델의 일반화 능력을 극대화하였음. 이를 통해 과적합을 방지하고 인지 수행 점수 예측의 정밀도를 확보함.

```
# 1. Define the parameters to test
param_grid = {
    'n_estimators': [100, 200, 300],      # Number of trees
    'learning_rate': [0.01, 0.05, 0.1,0.15, 0.2],   # How much each tree contributes
    'max_depth': [3, 4, 5],            # Maximum depth of each tree
    'subsample': [0.8, 1.0],              # Fraction of data used per tree (prevents overfitting)
}

# 2. Initialize a XGBoost model
xgb_base = XGBRegressor(random_state=42)

# 3. Configure the GridSearch
grid_search = GridSearchCV(
    estimator=xgb_base,
    param_grid=param_grid,
    scoring='r2',          # We want to optimize for the highest R2 score
    cv=5,                  # 5-Fold Cross Validation
    verbose=1,             # Prints updates so you know it hasn't crashed
    n_jobs=-1              # Uses all your computer's CPU cores to run faster
)
```

5.2 모델학습

```
best_xgb_model = grid_search.best_estimator_
y_pred_tuned = best_xgb_model.predict(X_test)

print("\n--- Tuned XGBoost Metrics ---")
print("Tuned MAE:", mean_absolute_error(y_test, y_pred_tuned))
print("Tuned MSE:", mean_squared_error(y_test, y_pred_tuned))
print("Tuned RMSE: ",np.sqrt(mean_squared_error(y_test, y_pred_tuned)))
print("Tuned R2:", r2_score(y_test, y_pred_tuned))
```

```
--- Tuned XGBoost Metrics ---
Tuned MAE: 7.973575291117319
Tuned MSE: 98.72436734157608
Tuned RMSE:  9.936013654458014
Tuned R2: 0.7991040246478158
```

5.3 모델 예측

○ 예측값 vs 실제값 비교

```
plt.figure(figsize=(14, 5))
plt.plot(y_test.values[:100], label="Actual (실제 정답)", color='dodgerblue', alpha=0.7, marker='o',
plt.plot(y_pred_tuned[:100], label="Predicted (모델 예측)", color='orange', alpha=0.9, linestyle='--'
plt.legend()
# Label
plt.title("Actual vs Predicted Comparison (Sample 100)", fontsize=16)
plt.xlabel("샘플 번호 (Test Samples)", fontsize=12)
plt.ylabel("인지 능력 점수 (Cognitive Performance)", fontsize=12)

plt.grid(True, linestyle=':', alpha=0.5)
plt.tight_layout()
plt.show()
```

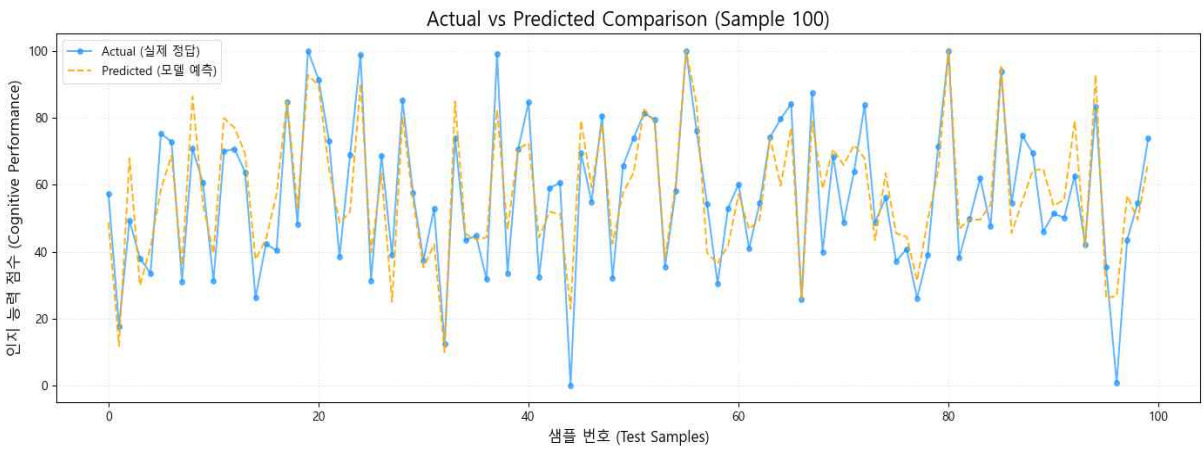

6. 프로토타이핑(화면)

6.1 모델 예측 및 데이터 처리 아키텍처

○ **다단계 모델링을 통한 정밀도 향상:**

- **보조 ML 모델 운영**: 사용자가 직접 산출하기 어려운 수치형 변수인 수면의 질(Quality of Sleep)을 객관적으로 도출하기 위해 별도의 보조 ML 모델을 선행 가동함.
- **데이터 흐름 및 파이프라인**: 웹 인터페이스를 통해 수집된 기초 수치 데이터(심박수, 수면 시간 등)는 보조 모델의 입력값으로 우선 활용되며, 여기서 산출된 정량적 지표가 최종 인지 수행 점수 예측을 위한 메인 모델의 핵심 독립 변수로 투입됨.
- **설계 목적**: 메인 모델에 직접 활용되지 않는 기초 데이터까지 체계적으로 수집·가공하여, 주관적 판단이 배제된 객관적인 수면 데이터 기반의 고도화된 인지 능력 예측을 구현하였음.

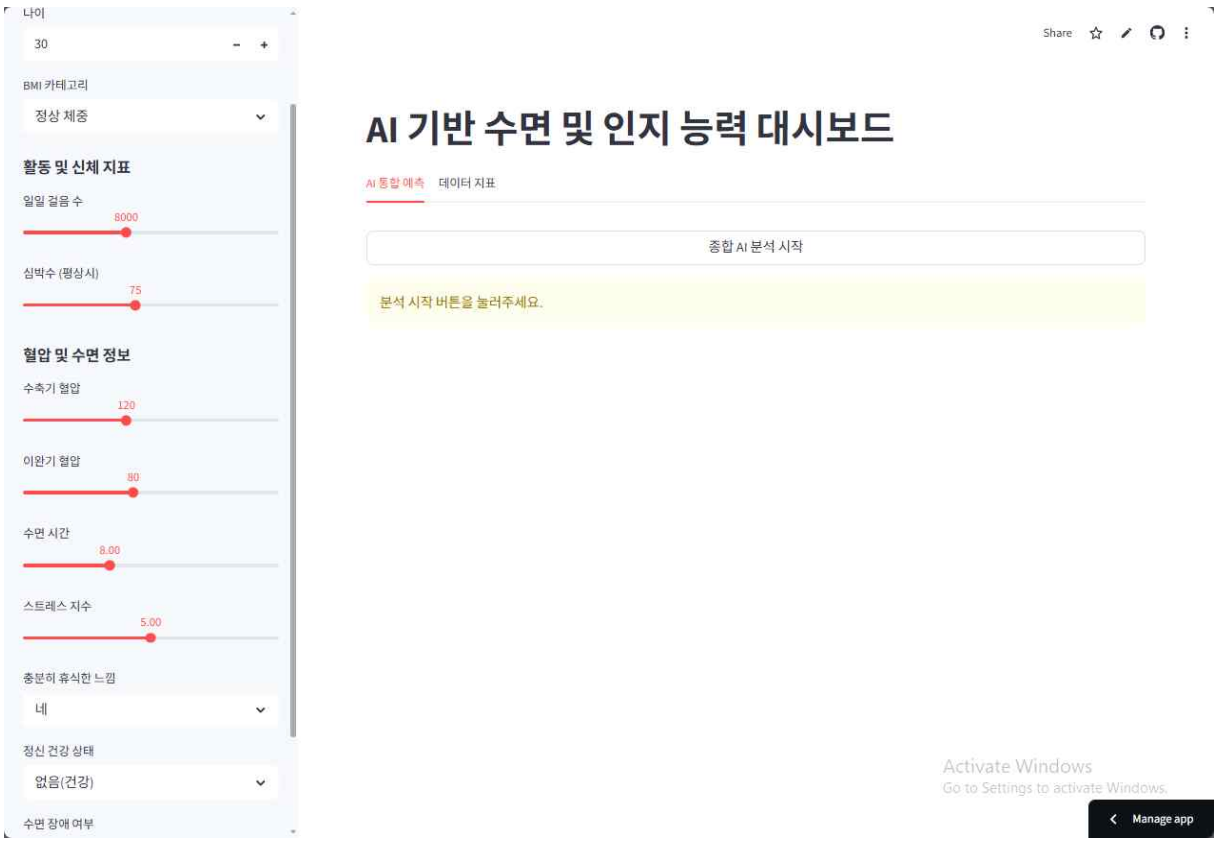

7. 결론 및 향후 계획

7.1 모델 개발 결과 요약

○ **최단계적 고도화를 통한 최적 예측 성능 확보**

■ 선형 회귀 모델을 기점으로 XGBoost와 GridSearchCV 최적화 과정을 거쳐 모델의 예측력을 단계적으로 향상하였음.

■ 최종 모델 검증 결과, 결정계수 R^2 0.80, MAE 7.97, RMSE 9.94 수준의 안정적인 지표를 기록하며 인지 수행 점수 예측에 대한 높은 신뢰도를 확보함.

○ **변수 중요도 분석 및 도메인 인사이트 도출**:

■ 피처 중요도 분석 결과, '수면의 질'이 인지 점수 결정에 가장 지배적인 영향력을 행사함을 정량적으로 입증하였음.

■ 이는 수면의 단순 물리적 양보다 질적 수준이 인지 기능 유지 및 작업 효율성에 더욱 핵심적인 요소라는 데이터 기반의 인사이트를 제공함.

7.2 한계점 및 향후 계획

○ **데이터 차원 확대 및 모델 설명력 (R^2) 개선**:

■ 기존 모델에서 제외되었던 잔여 변수들을 재평가하고, 추가적인 피처 엔지니어링을 수행하여 결정계수(R^2)를 최대로 끌어올릴 수 있는 최적의 피처 조합을 지속적으로 탐색할 예정임.

○ **사용자 편의성 증대를 위한 보조 모델 고도화**:

■ 사용자가 직접 기억하거나 측정하기 어려운 비가시적 지표(깊은 수면 단계, 야간 각성 횟수 등)를 혈압, 총 수면 시간, 활동량(걸음 수)과 같이 접근이 용이한 기초 수치로 추정하는 연산 로직을 정밀화하겠음.

■ 이를 통해 복잡한 생체 데이터 입력을 자동 산출되는 파생 변수로 대체함으로써, 서비스의 진입 장벽을 낮추는 동시에 실무적 활용 가치를 극대화할 계획임.