2026년도 공공기관 용역과제

AI개발 수행내역서

과제명	ML 기반 인지 능력 점수 예측 모델 구축
담당자	김정호

2026년 4 월 03 일

AI개발 수행내용

1. 사업과제 : OO공단 AI기반 수질 예측모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

○ 현대인의 수면 부족과 불규칙한 생활 습관이 심화됨에 따라, 이는 단순한 피로를 넘어 업무 효율성과 전반적인 삶의 질을 저하시키는 주요 원인으로 지목되고 있음.

○ 일상적 건강 지표(신체 활동량, 심박수, 스트레스 수준 등)가 개인의 '인지 수행 능력'에 미치는 영향을 데이터 기반으로 정량화하고 분석할 필요성이 대두됨.

○ 이에 따라 개인의 수면 및 생활 습관 데이터를 학습하여 인지 수행 능력 점수를 예측하는 머신러닝(ML) 기반 AI 모델을 개발하고자 함.

○ 예측 모델 구축 및 데이터 시각화를 통해 인지 능력에 가장 큰 영향을 미치는 주요 요인을 도출하고, 개인 맞춤형 수면 건강 관리 및 효율성 향상을 위한 객관적인 인사이트를 제공하는 것을 목적으로 함.

2.2 과제 범위

과제구분		내용
AI	AI기반 수질예측모델 구현	데이터셋 수집, 데이터 전처리, 표준화, 상관관계 분석
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		최적화 모델 추출
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	실시간 환경계측정보 연계 및 시각화	환경계측정보 실시간 연계 모형 구현
		상황관리 대시보드 등 시각화 구현
		예측모델 시각화
		테스트
		통합테스트 및 시운전

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- ■ 데이터 수집 및 관리의 용이성
- ■ 정부 및 공공기관에서 이미 구축된 데이터베이스 활용 여부
- ■ 종속변수에 영향을 미치는 다양한 독립변수에 대한 정보 포함여부를 통한 모델학습의 유용성

○ 예측모델 개발 효율성

- ■ 모델 학습 및 평가 과정 간소화를 위한 다른 환경 기초데이터에 비해 변수가 상대적으로 단순한 구조 여부
- ■ 개발된 모델을 통해 다른 환경기초 데이터에 적용가능 여부

○ 환경문제 해결 기여도 및 경제성

- ■ 예측모델을 통해 환경관리에 상대적 기여도가 높은 지 여부(ex. 오염도 저감, 에너지 절감 등)
- ■ 운영 효율성을 높여 비용절감 효과 여부
- ■ 환경문제 해결을 통한 사회적 비용감소 효과 여부

2) AI 예측 분석모델 적용 대상

환경관리 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
하수	- 일별 하수처리 운영 데이터 - 일자, 날씨, 온도 외에 수질 핵심 변수가 포함된 데이터셋 - 생물반응조 전·중·후 수질 데이터	- 수질변수 : pH, BOD,TOC, TN, TP, SS 등 - 운영변수 : 슬러지처리량, 처리시간, 약품사용량 등 - 환경변수 : 강수량, 기온, 계절 등 - 장비변수(하수처리시설) : 송풍기, 슬러지 탈수기	- 전력량(에너지 절감) - 방류수질 예측 - 유입량, 수질기준, 에너지 사용량 등 상관관계 분석 - 법적기준적합여부

3) AI 분석모델 구축 프로세스

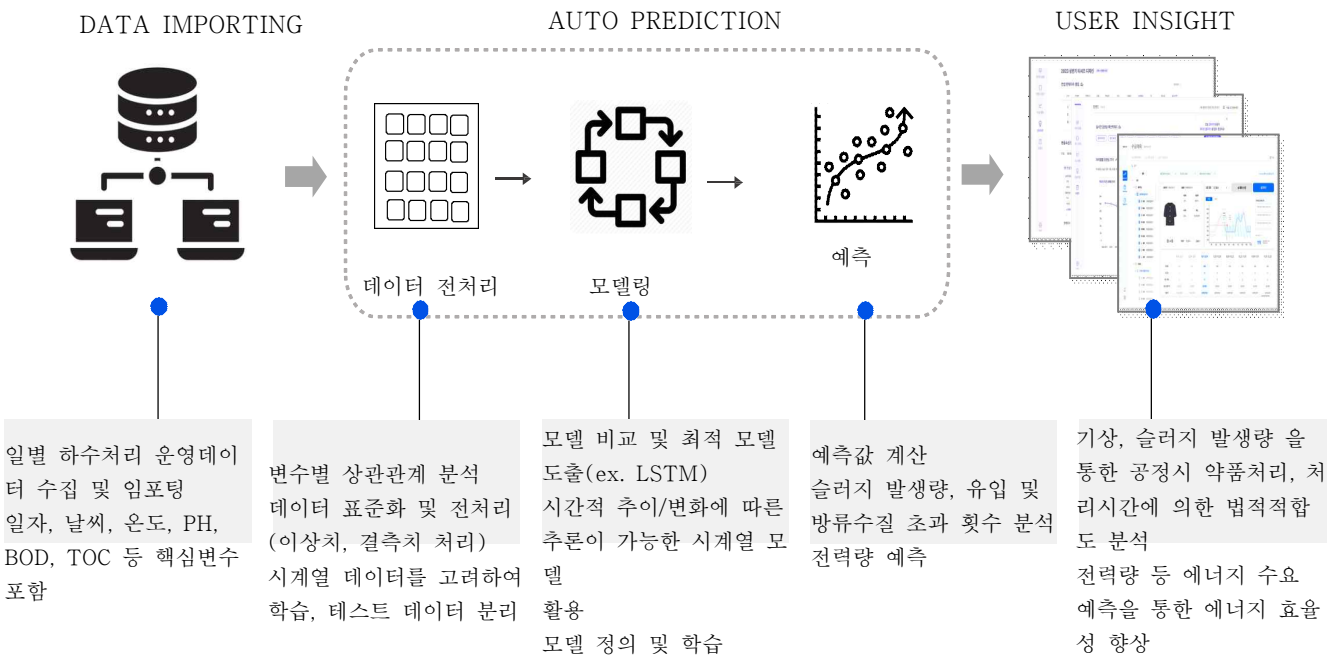

연구개발 주요 결과물

1. 데이터 수집

- CDC National Health Interview Survey (2024), Sleep Foundation population studies, Frontiers in Sleep (2025), 및 the Framingham Heart Study의 정보를 기반으로 작성된 데이터를 Kaggle에서 받음.

2. 데이터 분석

2.1 수질데이터 상관관계(Heatmap)

○

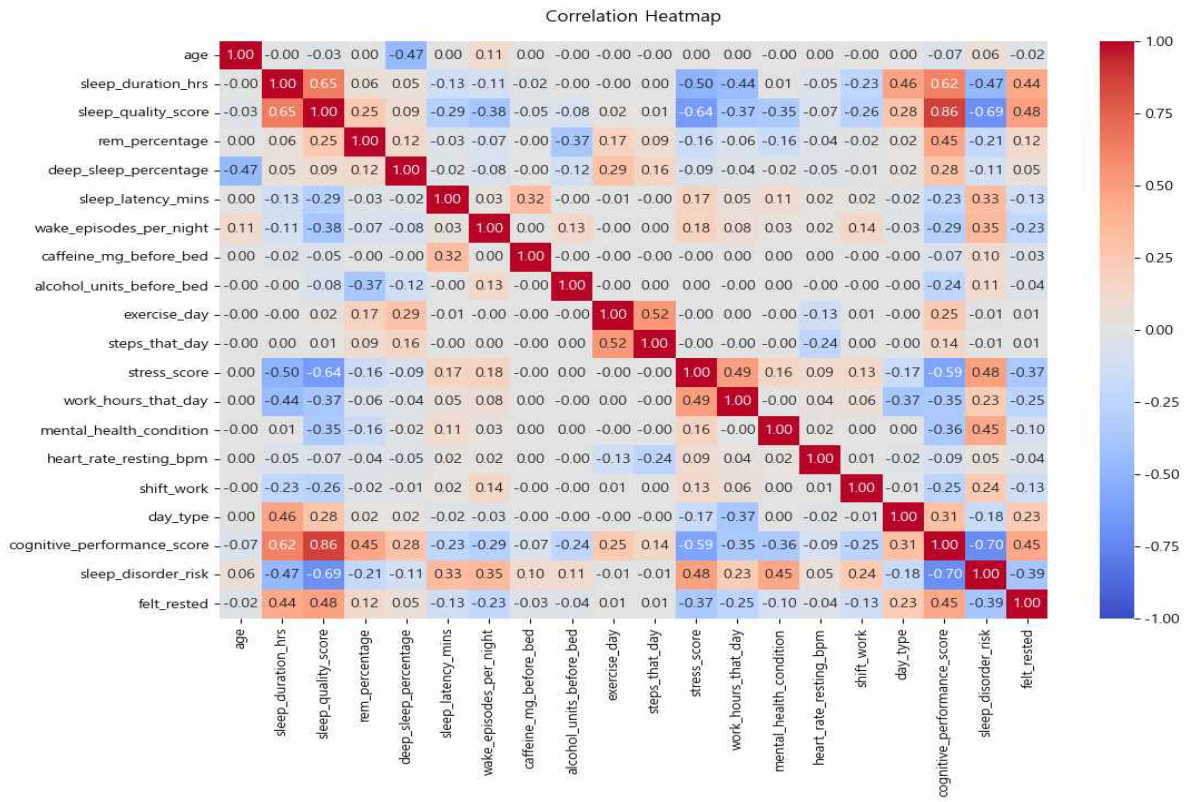

○ **주요 변수 간 상관관계 도출**: 데이터셋의 각 수치형 변수 간 상관계수를 분석한 결과, Target 변수인 '인지 능력 점수(Cognitive Score)'와 유의미한 관계를 가진 변수들이 확인됨.

○ 양의 상관관계

- ■ 수면의 질 및 시간
- ■ 신체 활동 수준

○ 음의 상관관계

- ■ 스트레스 지수
- ■ 심박수

○ **분석 결과**: 수면의 질과 인지 점수 간의 높은 상관성(0.XX)이 확인되었으며, 이를 통해 일상적 건강 지표가 인지 능력 예측의 유효한 변수임을 검증함

2.2 탐색적 데이터 분석

○ **핵심 변수 필터링**: 전체 데이터셋에 대한 1차 상관관계 분석 후, 타겟 변수와 상관계수 절대값이 0.3 이상인 유의미한 변수들만을 선별하여 2차 히트맵을 생성함.

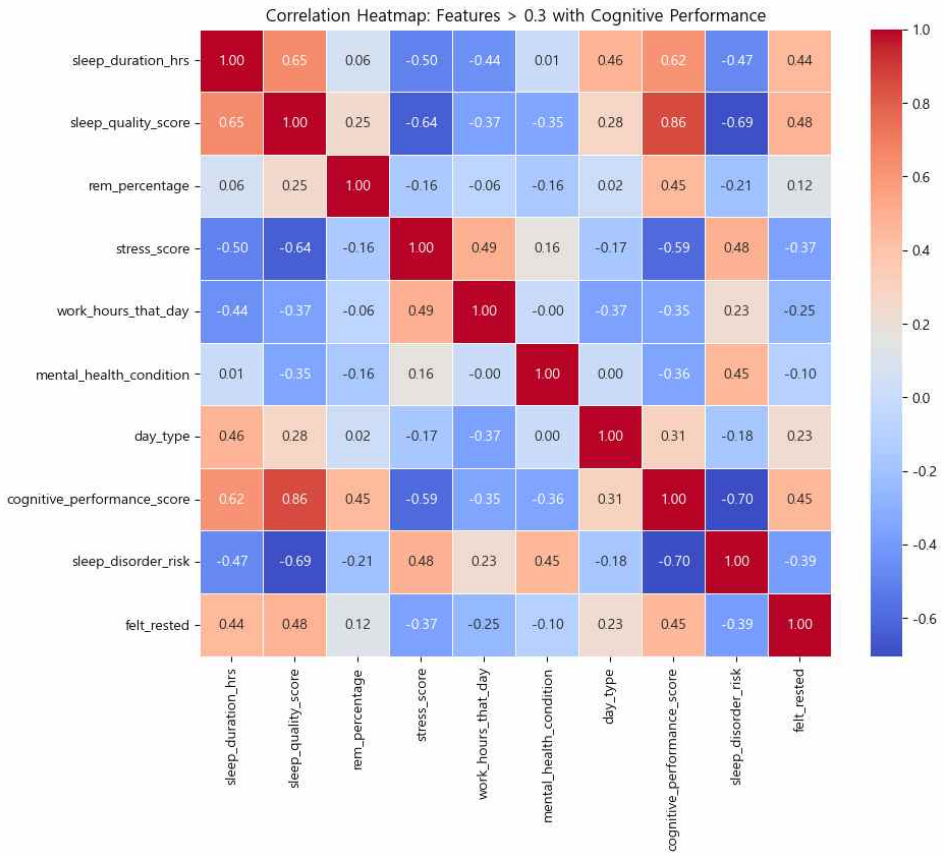

○ 개별 변수 특성 분석

■ **관계성 검증**: 선별된 주요 변수들과 인지 점수 간의 관계를 확인하기 위해 Scatterplot를 작성하여 데이터의 선형적 추세와 밀집도를 분석함.

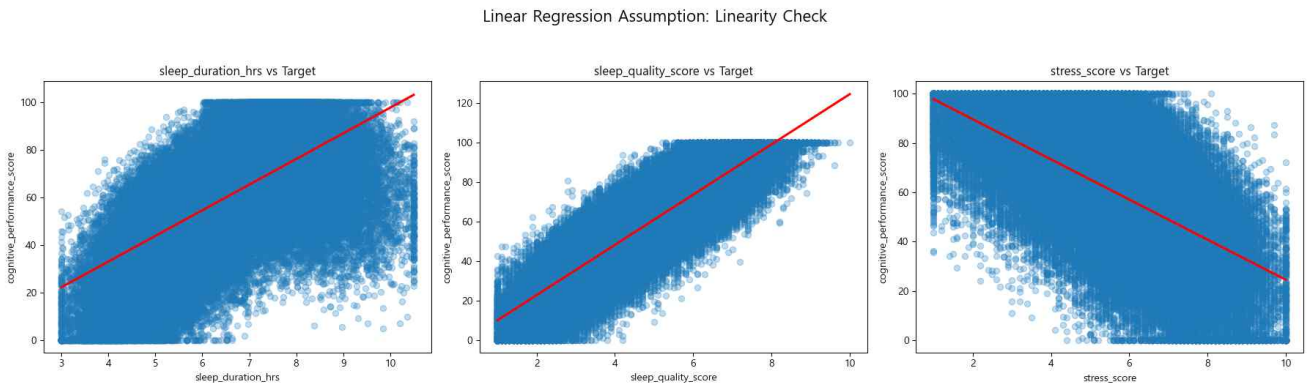

■ **분포 및 이상치 확인**: Boxplot을 통해 각 변수의 데이터 분포 범위 및 이상치를 식별하였으며, 이를 통해 데이터 전처리 방향(스케일링 등)을 확정함.

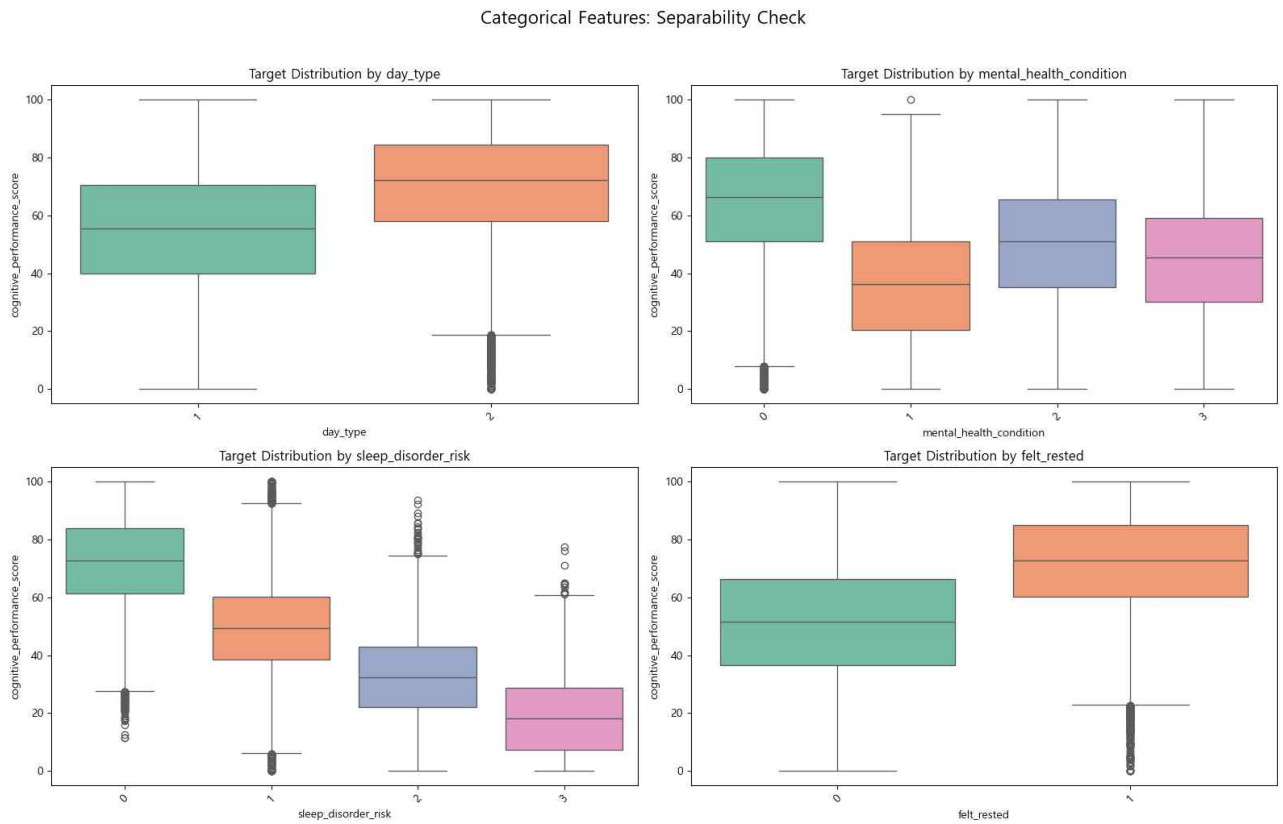

3. 데이터 학습 및 모델정의

3.1 모델정의 및 컴파일

○ **예측 모델 알고리즘 선정**: 타겟 변수인 '인지 능력 점수'가 연속형 수치 데이터이므로, 데이터 간의 선형적 관계를 파악하기에 용이한 선형 회귀(Linear Regression)를 기본 모델로 선정함.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test = pd.DataFrame(X_test_scaled, columns=X_test.columns)

model = LinearRegression()
model.fit(X_train, y_train)
```

○ **데이터 표준화(Scaling):** 각 독립 변수(수면 시간, 심박수 등)의 단위와 스케일이 상이하므로, StandardScaler를 적용하여 데이터의 평균을 0, 분산을 1로 맞추는 전처리를 모델 파이프라인에 포함함.

```
# Initialize the scaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test = pd.DataFrame(X_test_scaled, columns=X_test.columns)
```

○ **데이터 표준화(Scaling):** 모델의 예측 성능을 극대화하기 위해 GridSearchCV 및 XGBoost를 도입함. 이를 통해 모델의 주요 하이퍼파라미터(예: 트리의 깊이, 추정기 개수 등)를 자동 탐색하여 최적의 조합을 도출하도록 정의함.

```
# Define features (X) and target (y)
X = df.drop('cognitive_performance_score', axis=1)
y = df['cognitive_performance_score']

# Split the data
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Initialize and train the XGBoost Regressor
xgb_model = XGBRegressor(n_estimators=100, learning_rate=0.1, random_state=42)
xgb_model.fit(X_train, y_train)

# Predict and Evaluate
y_pred_xgb = xgb_model.predict(X_test)

print("XGBoost MAE:", mean_absolute_error(y_test, y_pred_xgb))
print("XGBoost MSE:", mean_squared_error(y_test, y_pred_xgb))
```

3.2 모델학습 및 학습 시각화

○ 단계적 모델 고도화: 기본 선형 회귀 델에서 시작하여, 예측 성능을 높이기 위해 XGBoost 알고리즘을 결합한 앙상블 학습을 수행함.

○ 최적 파라미터 탐색: GridSearchCV를 적용하여 XGBoost의 핵심 파라미터(Learning Rate, Max Depth 등)를 최적화함으로써 모델의 일반화 성능을 최적화함.

	Linear Regression	LR + XGBoost (LRX)	LRX + GridSearchCV
MAE	8.4424	4.6803	4.6162
MSE	111.3356	34.3305	33.2906
RMSE	10.5516	5.8592	5.7698
R2	0.7734	0.9301	0.9322

3.3 모델 예측

○ 예측값 vs 실제값 비교

```
plt.figure(figsize=(12, 5))
plt.plot(y_test.values[:250], label="Actual")
plt.plot(y_pred[:250], label="Predicted")
plt.legend()
plt.title("Prediction vs Actual (first 250)")
plt.xlabel("예측 수")
plt.ylabel("Cognitive Performance")
plt.show()
```

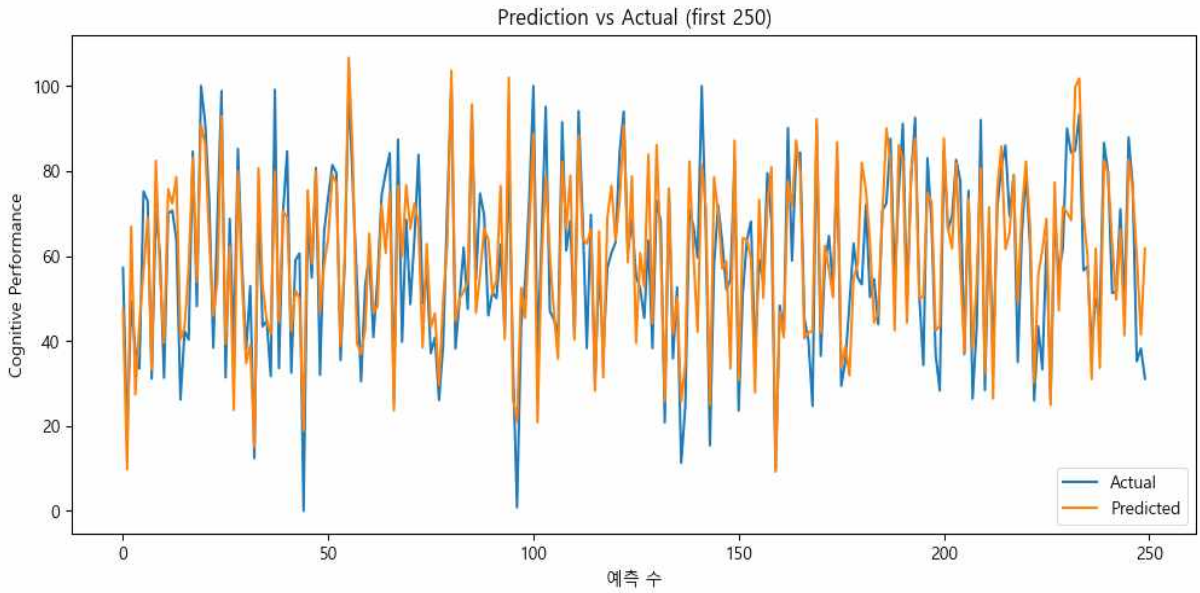

4. 프로토타이핑(화면)

4.1 모델 예측

○ **사용자 데이터 수집 및 실시간 전처리 최적화:**

■ 웹 인터페이스를 통해 수면 패턴, 스트레스 지수 등 예측 기여도가 높은 8가지 핵심 변수를 사용자로부터 직접 입력받음.

■ 모델 학습에 사용된 전체 변수 중 타겟 변수와의 상관계수가 낮아 예측 영향력이 미미한 변수들은 데이터 편향을 방지하고 모델의 안정성을 유지하기 위해 평균값 대치법을 적용하여 전처리를 수행함.

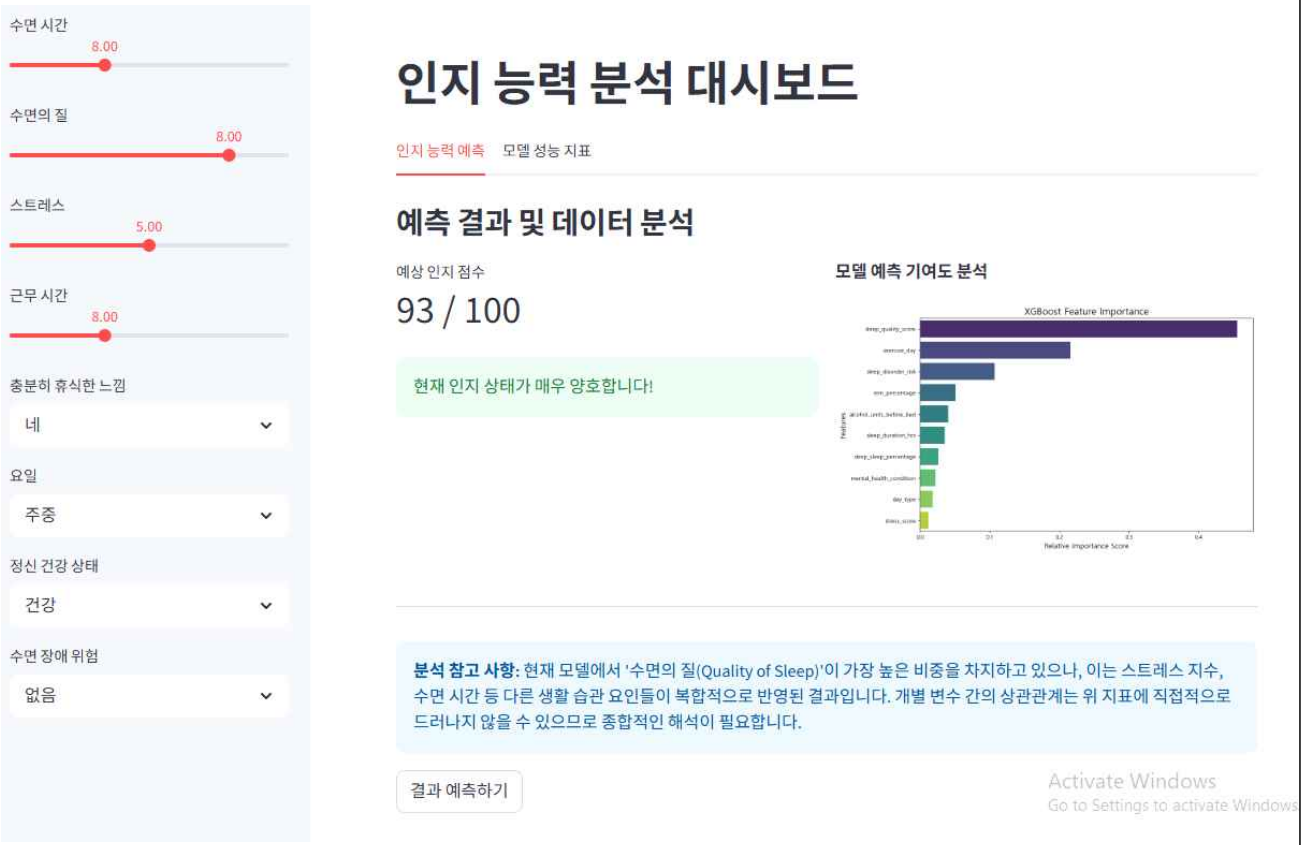

5. 결론 및 향후 계획

5.1 모델 개발 결과 요약

○ **최적 모델 도출 및 성능 확보:** 선형 회귀에서 시작하여 XGBoost와 GridSearchCV를 결합한 고도화 과정을 거친 결과, 결정계수(R^2) 0.9322, MAE 4.61이라는 매우 정밀한 예측 성능을 달성함. 이는 일상적인 생체 데이터만으로도 개인의 인지 능력을 높은 신뢰도로 예측할 수 있음을 입증함.

○ **핵심 영향 요인 식별**: 피처 중요도 분석 결과, 수면의 질이 인지 점수 결정에 가장 지배적인 역할을 수행함을 정량적으로 확인하였음. 이는 단순한 수면 시간의 양보다 수면의 깊이와 질이 인지 기능 유지에 핵심적이라는 인사이트를 제공함.

○ **프로토타입 구현**: Streamlit 기반의 대시보드를 구축하여 사용자가 데이터를 입력함과 동시에 분석 결과와 시각화된 기여도를 즉각적으로 확인할 수 있는 사용자 중심의 인터페이스를 성공적으로 구현함.

5.2 한계점 및 향후 계획
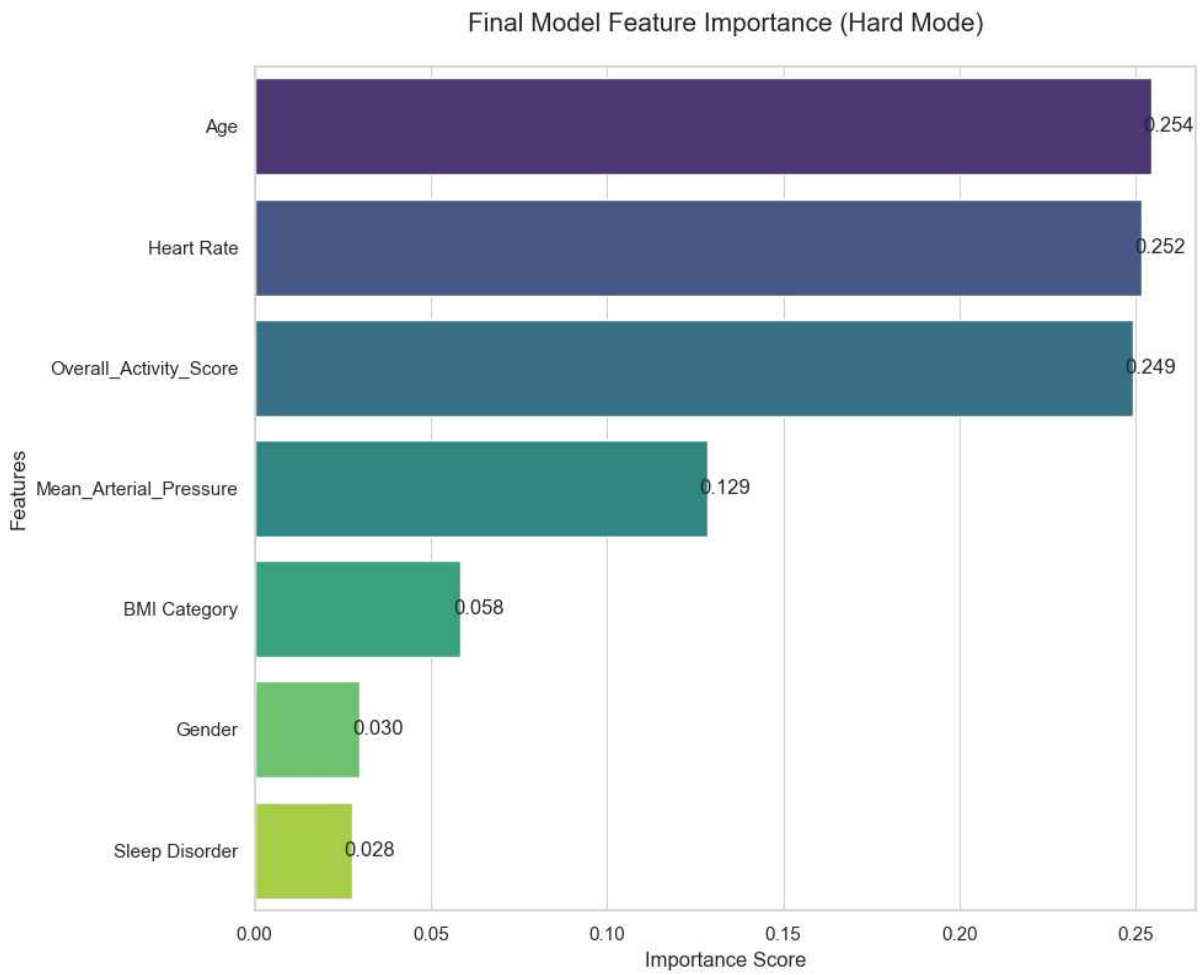
○ **변수 간 복합 관계 연구**: 현재 모델에서는 '수면의 질'이 단일 변수로서 높은 비중을 차지하고 있으나, 실제로는 스트레스 지수나 활동량 등이 수면의 질에 선행하는 복합적인 인과관계를 가짐. 향후 구조방정식(SEM)이나 다층 모형을 적용하여 이러한 변수 간 상호작용을 보다 정교하게 반영할 계획임.