2026년도 공공기관 용역과제

AI개발 수행내역서

과제명	ML 기반 인지 능력 점수 예측 모델 구축
담당자	김정호

2026년 4 월 03 일

AI개발 수행내용

1. 사업과제 : ML 기반 인지 능력 점수 예측 모델 구축

2. 개요 및 현황

2.1 추진배경 및 목적

○ 현대인의 수면 부족과 불규칙한 생활 습관이 심화됨에 따라, 이는 단순한 피로를 넘어 업무 효율성과 전반적인 삶의 질을 저하시키는 주요 원인으로 지목되고 있음.

○ 일상적 건강 지표(신체 활동량, 심박수, 스트레스 수준 등)가 개인의 '인지 수행 능력'에 미치는 영향을 데이터 기반으로 정량화하고 분석할 필요성이 대두됨.

○ 이에 따라 개인의 수면 및 생활 습관 데이터를 학습하여 인지 수행 능력 점수를 예측하는 머신러닝(ML) 기반 AI 모델을 개발하고자 함.

○ 예측 모델 구축 및 데이터 시각화를 통해 인지 능력에 가장 큰 영향을 미치는 주요 요인을 도출하고, 개인 맞춤형 수면 건강 관리 및 효율성 향상을 위한 객관적인 인사이트를 제공하는 것을 목적으로 함.

2.2 과제 범위

과제구분		내용
ML	ML기반 인지 능력 점수 예측 모델 구축	데이터셋 수집, 데이터 전처리, 표준화, 상관관계 분석
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		최적화 모델 추출
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

■ **수집 및 관리 용이성**: 웨어러블 및 모바일 기기를 통해 정형화된 생체·생활 지표를 확보할 수 있어 데이터 관리와 분석의 연속성 보장이 가능함.

■ **정변수의 유효성**: 수면의 질, 스트레스 등 인지 능력과 직결된 다각적 독립변수를 포함하여 분석의 정밀도와 결과의 신뢰도를 확보할 수 있는 지표를 선정함.

○ 예측모델 개발 효율성

■ **모델 확장성**: 개발된 분석 로직이 향후 정신 건강 관리 및 집중력 분석 등 유사 헬스케어 영역으로 수평적 확장이 가능한지를 최우선으로 고려함

○ 사회적 기여도 및 경제성

■ **국민 건강 및 생산성 기여**: 개인별 인지 상태의 객관적 지표를 제공함으로써 수면 부족에 따른 사회적 생산성 손실을 줄이고 국민 삶의 질 향상에 기여함.

■ **비용 절감 및 가치 창출**: 인지 저하 위험군의 조기 식별을 통해 장기적 의료 비용을 절감하며, 맞춤형 가이드 제공을 통한 디지털 헬스케어의 실무적 가치를 창출함.

2) AI 예측 분석모델 적용 대상

분석 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
개인 건강 및 인지 관리	- 일상 생활 및 수면 데이터 - 일별 수면 패턴 및 활동 데이터 - 수면의 질, 스트레스 등 핵심 지표가 포함된 데이터셋	수면 지표: 수면 시간 및 질, 수면 장애 여부 등 생체 지표: 스트레스 지수, 심박수(BPM) 등 활동 지표: 신체 활동량등 환경 변수: 요일(주중/주말), 기상 패턴 등	인지 능력 점수 예측

3) ML 분석모델 구축 프로세스

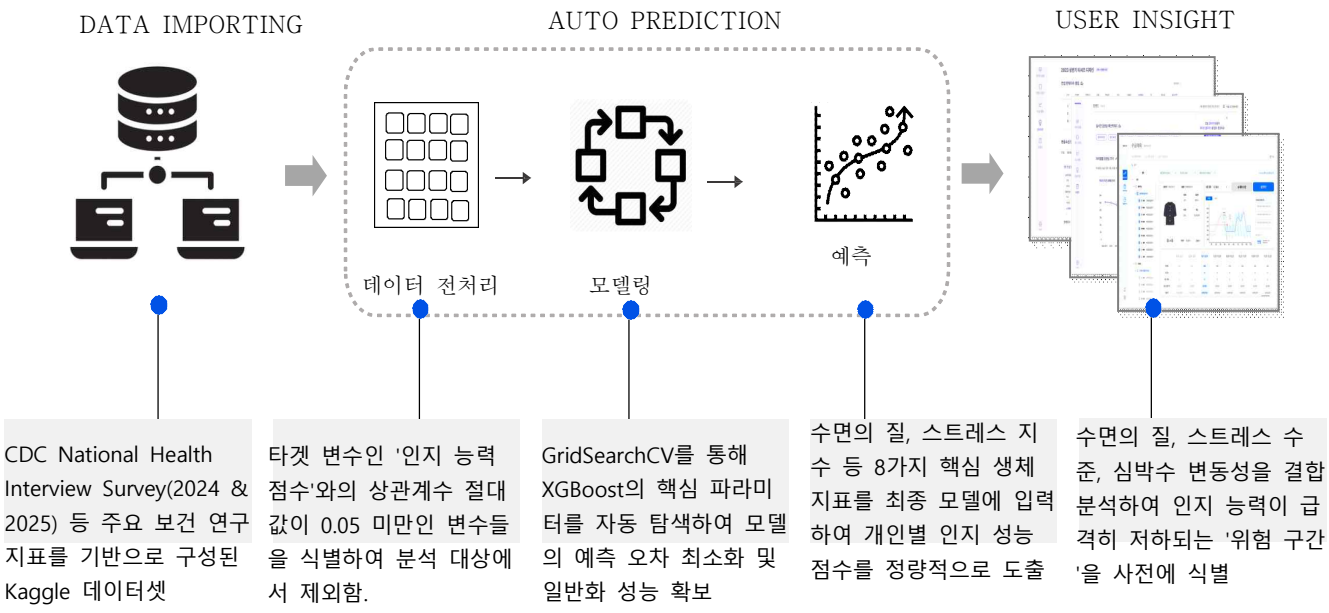

연구개발 주요 결과물

1. 데이터 수집

- CDC National Health Interview Survey (2024), Sleep Foundation population studies, Frontiers in Sleep (2025), 및 the Framingham Heart Study의 정보를 기반으로 작성된 데이터를 Kaggle에서 받음.

2. 데이터 분석

2.1 수질데이터 상관관계(Heatmap)

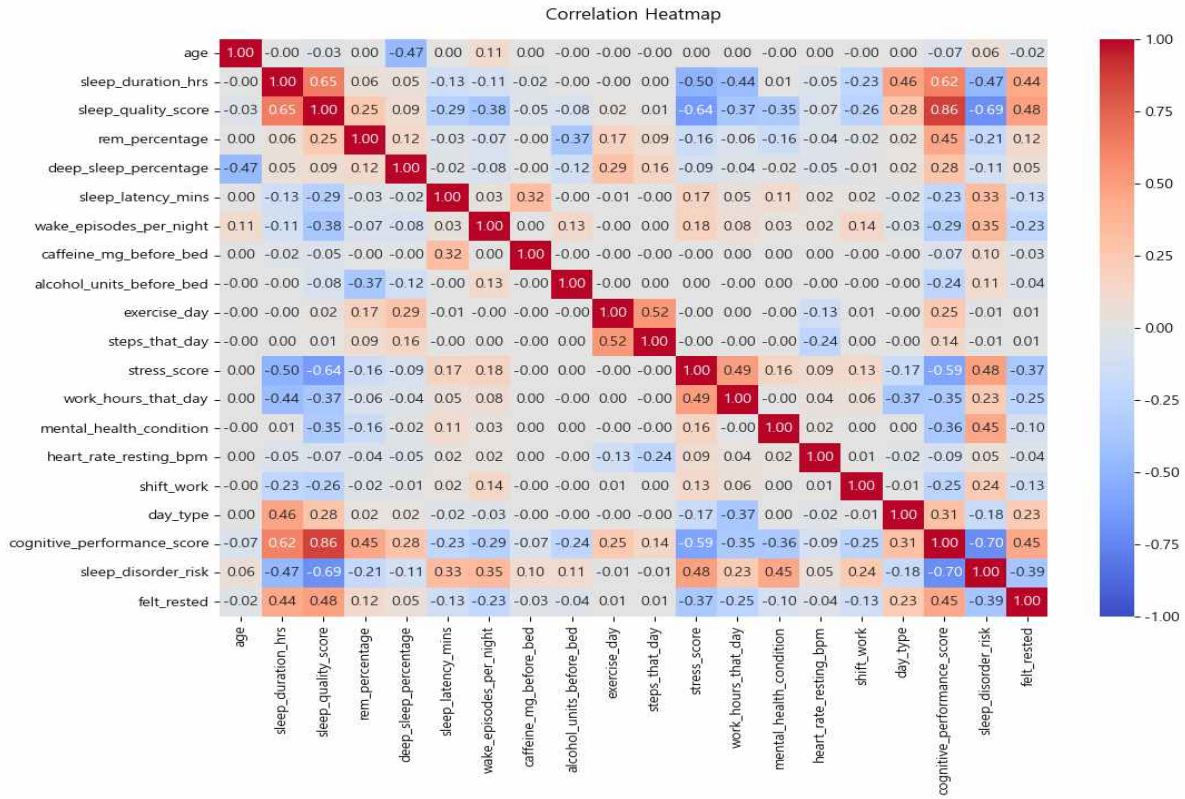

○ **주요 변수 간 상관관계 도출**: 데이터셋의 각 수치형 변수 간 상관계수를 분석한 결과, Target 변수인 '인지 능력 점수(Cognitive Score)'와 유의미한 관계를 가진 변수들이 확인됨.

○ 양의 상관관계

- ■ 수면의 질 및 시간
- ■ 신체 활동 수준

○ 음의 상관관계

- ■ 스트레스 지수
- ■ 심박수

○ **분석 결과**: 수면의 질과 인지 점수 간의 높은 상관성(0.XX)이 확인되었으며, 이를 통해 일상적 건강 지표가 인지 능력 예측의 유효한 변수임을 검증함

2.2 탐색적 데이터 분석

○ **핵심 변수 필터링**: 전체 데이터셋에 대한 1차 상관관계 분석 후, 타겟 변수와 상관계수 절대값이 0.3 이상인 유의미한 변수들만을 선별하여 2차 히트맵을 생성함.

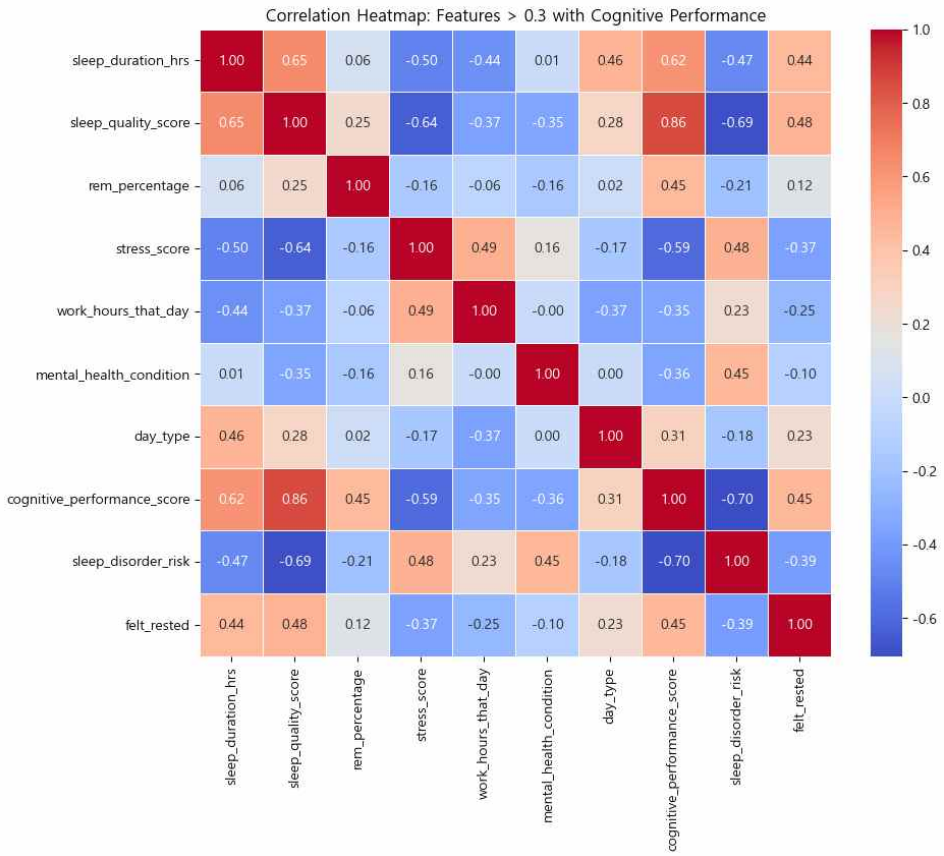

○ 개별 변수 특성 분석

■ **관계성 검증**: 선별된 주요 변수들과 인지 점수 간의 관계를 확인하기 위해 Scatterplot를 작성하여 데이터의 선형적 추세와 밀집도를 분석함.

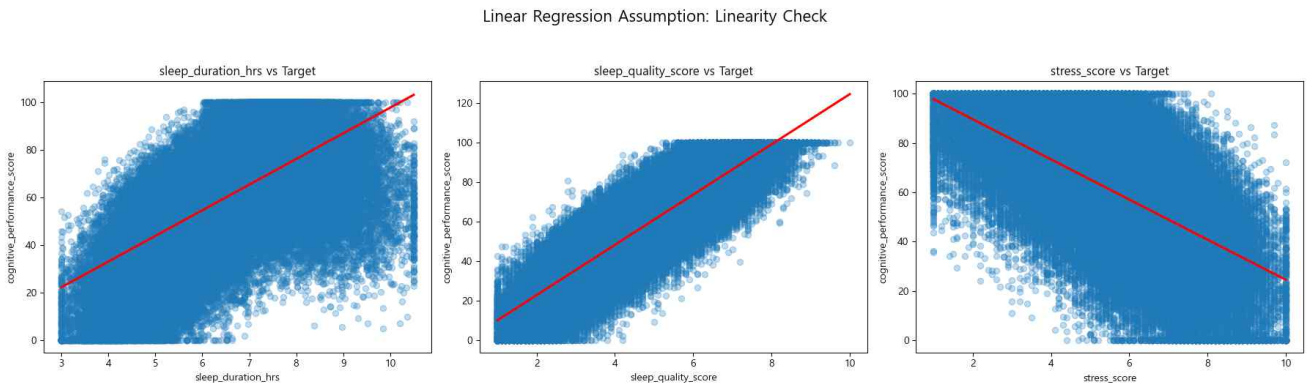

■ **분포 및 이상치 확인**: Boxplot을 통해 각 변수의 데이터 분포 범위 및 이상치를 식별하였으며, 이를 통해 데이터 전처리 방향(스케일링 등)을 확정함.

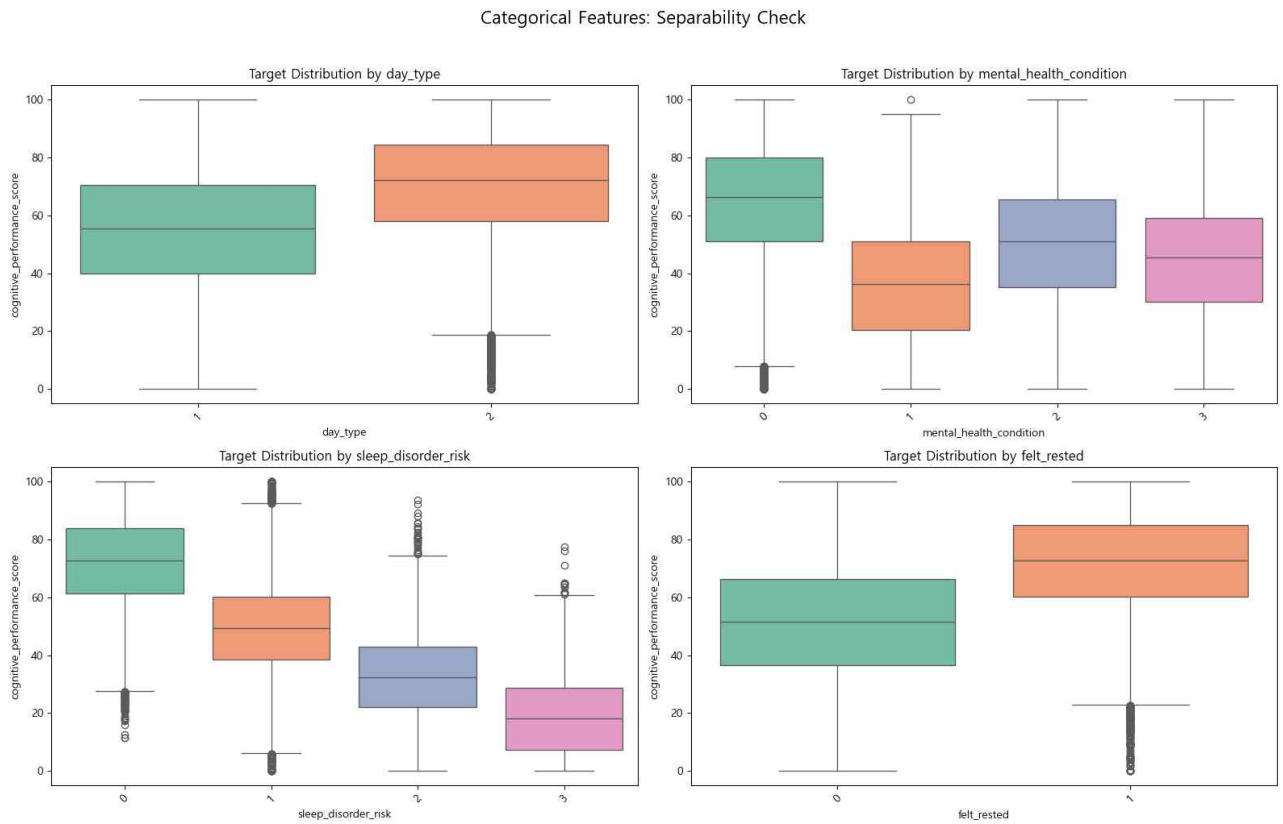

3. 데이터 학습 및 모델정의

3.1 모델정의 및 컴파일

○ **예측 모델 알고리즘 선정**: 타겟 변수인 '인지 능력 점수'가 연속형 수치 데이터이므로, 데이터 간의 선형적 관계를 파악하기에 용이한 선형 회귀(Linear Regression)를 기본 모델로 선정함.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test = pd.DataFrame(X_test_scaled, columns=X_test.columns)

model = LinearRegression()
model.fit(X_train, y_train)
```

○ **데이터 표준화(Scaling):** 각 독립 변수(수면 시간, 심박수 등)의 단위와 스케일이 상이하므로, StandardScaler를 적용하여 데이터의 평균을 0, 분산을 1로 맞추는 전처리를 모델 파이프라인에 포함함.

```
# Initialize the scaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test = pd.DataFrame(X_test_scaled, columns=X_test.columns)
```

○ **데이터 표준화(Scaling):** 모델의 예측 성능을 극대화하기 위해 GridSearchCV 및 XGBoost를 도입함. 이를 통해 모델의 주요 하이퍼파라미터(예: 트리의 깊이, 추정기 개수 등)를 자동 탐색하여 최적의 조합을 도출하도록 정의함.

```
# Define features (X) and target (y)
X = df.drop('cognitive_performance_score', axis=1)
y = df['cognitive_performance_score']

# Split the data
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Initialize and train the XGBoost Regressor
xgb_model = XGBRegressor(n_estimators=100, learning_rate=0.1, random_state=42)
xgb_model.fit(X_train, y_train)

# Predict and Evaluate
y_pred_xgb = xgb_model.predict(X_test)

print("XGBoost MAE:", mean_absolute_error(y_test, y_pred_xgb))
print("XGBoost MSE:", mean_squared_error(y_test, y_pred_xgb))
```

3.2 모델학습 및 학습 시각화

○ 단계적 모델 고도화: 기본 선형 회귀 델에서 시작하여, 예측 성능을 높이기 위해 XGBoost 알고리즘을 결합한 앙상블 학습을 수행함.

○ 최적 파라미터 탐색: GridSearchCV를 적용하여 XGBoost의 핵심 파라미터(Learning Rate, Max Depth 등)를 최적화함으로써 모델의 일반화 성능을 최적화함.

	Linear Regression	LR + XGBoost (LRX)	LRX + GridSearchCV
MAE	8.4424	4.6803	4.6162
MSE	111.3356	34.3305	33.2906
RMSE	10.5516	5.8592	5.7698
R2	0.7734	0.9301	0.9322

3.3 모델 예측

○ 예측값 vs 실제값 비교

```
plt.figure(figsize=(12, 5))
plt.plot(y_test.values[:250], label="Actual")
plt.plot(y_pred[:250], label="Predicted")
plt.legend()
plt.title("Prediction vs Actual (first 250)")
plt.xlabel("예측 수")
plt.ylabel("Cognitive Performance")
plt.show()
```

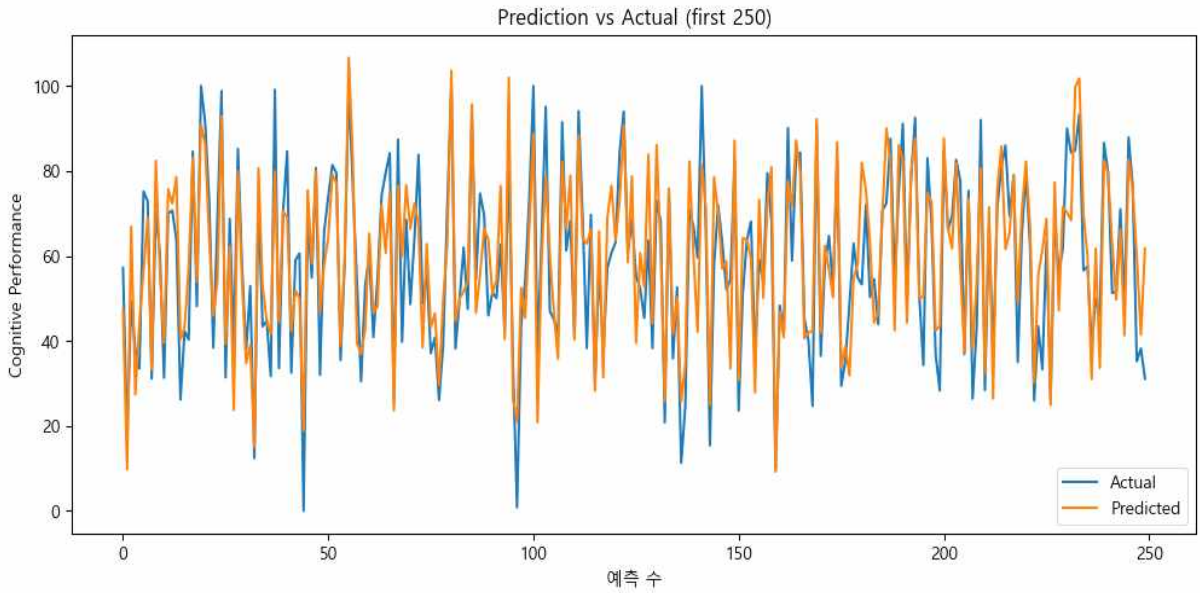

4. 프로토타이핑(화면)

4.1 모델 예측

○ **사용자 데이터 수집 및 실시간 전처리 최적화:**

■ 웹 인터페이스를 통해 수면 패턴, 스트레스 지수 등 예측 기여도가 높은 8가지 핵심 변수를 사용자로부터 직접 입력받음.

■ 모델 학습에 사용된 전체 변수 중 타겟 변수와의 상관계수가 낮아 예측 영향력이 미미한 변수들은 데이터 편향을 방지하고 모델의 안정성을 유지하기 위해 평균값 대치법을 적용하여 전처리를 수행함.

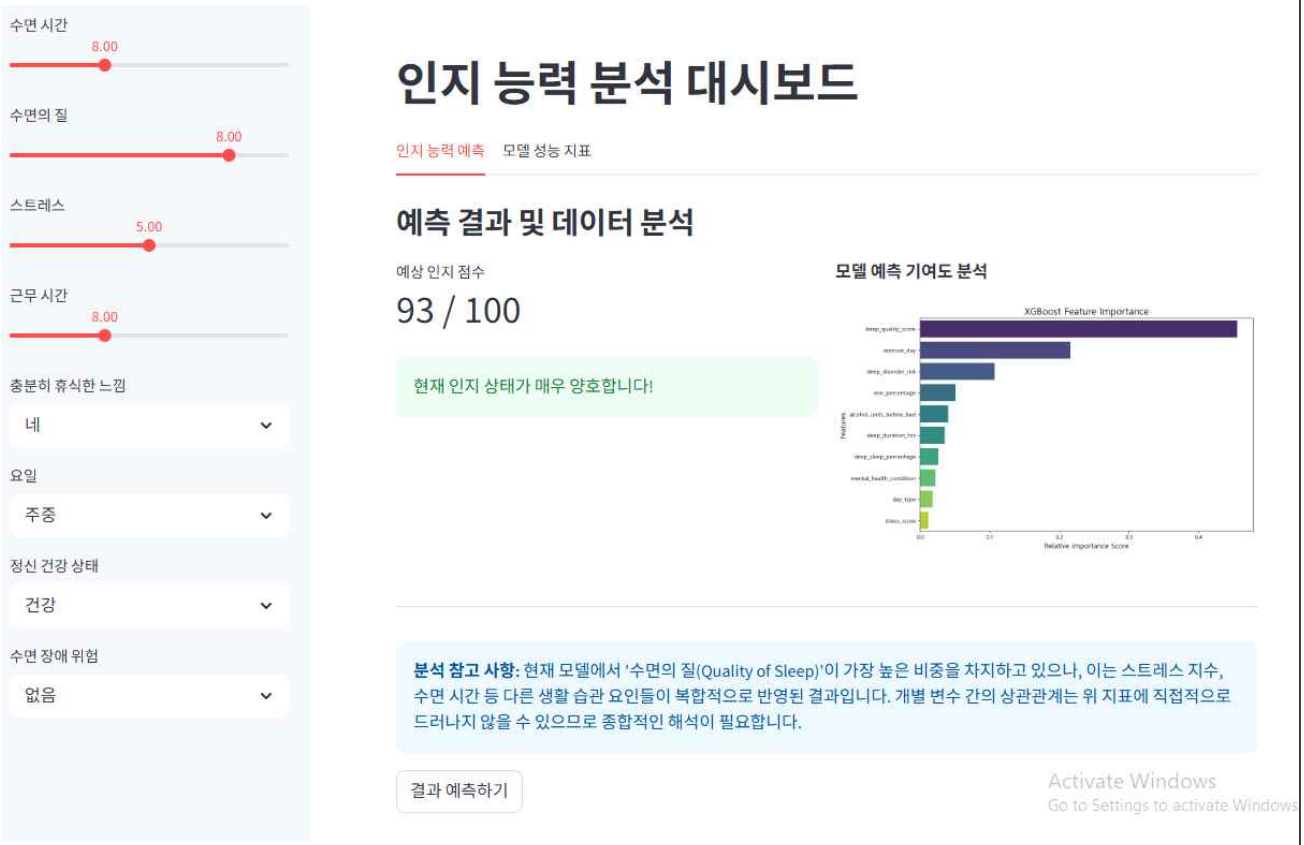

5. 결론 및 향후 계획

5.1 모델 개발 결과 요약

○ **최적 모델 도출 및 성능 확보:** 선형 회귀에서 시작하여 XGBoost와 GridSearchCV를 결합한 고도화 과정을 거친 결과, 결정계수(R^2) 0.9322, MAE 4.61이라는 매우 정밀한 예측 성능을 달성함. 이는 일상적인 생체 데이터만으로도 개인의 인지 능력을 높은 신뢰도로 예측할 수 있음을 입증함.

○ **핵심 영향 요인 식별**: 피처 중요도 분석 결과, 수면의 질이 인지 점수 결정에 가장 지배적인 역할을 수행함을 정량적으로 확인하였음. 이는 단순한 수면 시간의 양보다 수면의 깊이와 질이 인지 기능 유지에 핵심적이라는 인사이트를 제공함.

5.2 한계점 및 향후 계획
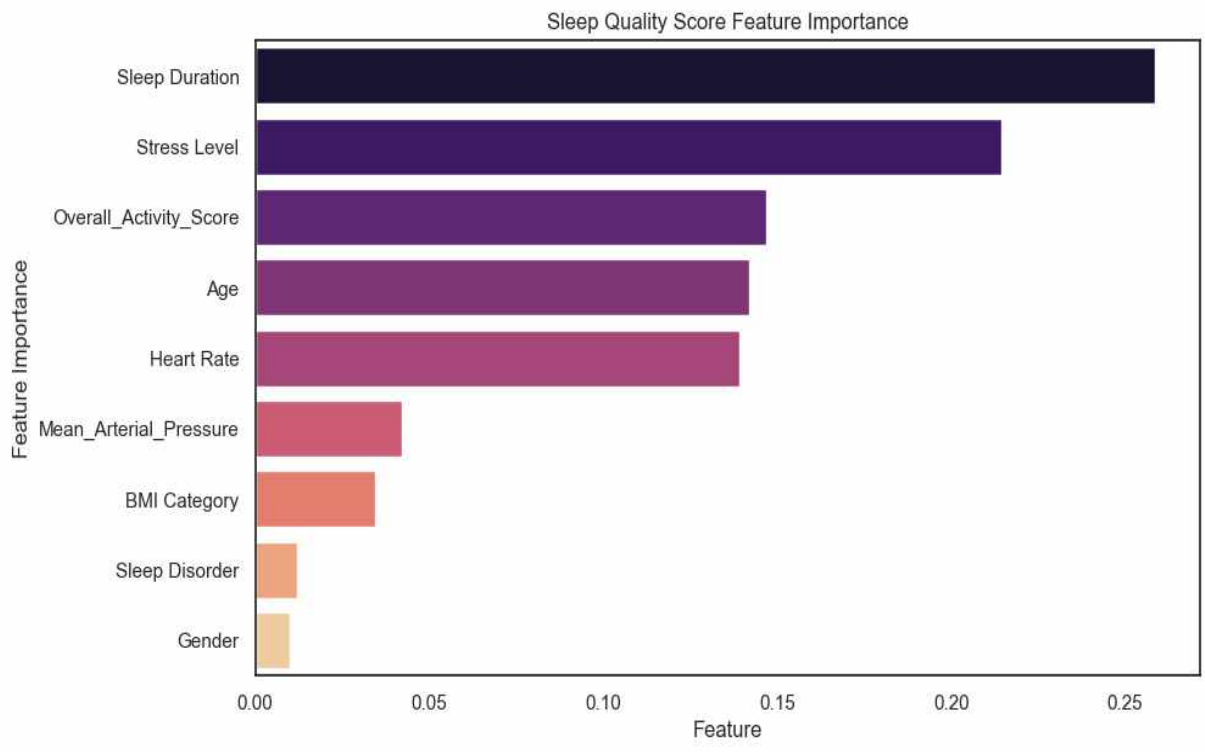
○ **변수 간 복합 관계 연구**: 현재 모델에서는 '수면의 질'이 단일 변수로서 높은 비중을 차지하고 있으나, 실제로는 스트레스 지수나 활동량 등이 수면의 질에 선행하는 복합적인 인과관계를 가짐. 향후 구조방정식(SEM)이나 다층 모형을 적용하여 이러한 변수 간 상호작용을 보다 정교하게 반영할 계획임.